



universität
uulm

Fakultät für Ingenieurwissenschaften, Informatik und Psychologie

Institut für Psychologie und Pädagogik

Abteilung Differentielle Psychologie und Psychologische Diagnostik

Machine Learning in der psychologischen Diagnostik

– Stand der aktuellen Forschung

Hausarbeit zum Erwerb zwei fehlender ECTS-Punkte im Bereich Diagnostik

Vorgelegt am 6. Mai 2022 von:

Luca David Cermak, B.Sc.

luca.cermak@uni-ulm.de

Matrikelnummer 981404

Studiengang Psychologie, B. Sc.

Prüfer:

Professor Dr. Oliver Wilhelm

Wörter im Text:

5.288 Wörter

Inhaltsverzeichnis

1	Einleitung	1
2	Theoretische Grundlagen	3
2.1	Grundlagen psychologischer Diagnostik	3
2.2	Kurze Einführung in das Machine Learning	4
2.3	Einführung in die Achtsamkeit	5
3	Aktuelle Machine Learning-Anwendungen	6
3.1	Computational Psychiatry	6
3.2	Mindful Machine Learning	8
3.3	Weitere Anwendungen in der psychologischen Diagnostik	10
4	Diskussion und Reflexion	11
4.1.1	Diskussion der Primärartikel	11
4.1.1.1	Computational Psychiatry	11
4.1.1.2	Mindful Machine Learning	14
4.1.1.3	Zusammenfassung	15
4.1.2	Diagnostische Einordnung des Machine Learning	15
5	Fazit und Ausblick	19
	Referenzen	20

1 Einleitung

Wie können psychische Erkrankungen effizienter erkannt und schneller behandelt werden? Im Hinblick auf lange Wartezeiten bei Richtlinienpsychotherapieplätzen beschäftigen sich die Medizin, Psychologie und Politik mit dieser Frage. Die Wartezeit auf einen Platz im Richtlinienpsychotherapieverfahren betrug im Jahr 2018 knapp 20 Wochen (Bundespsychotherapeutenkammer, 2018).

Diese Frage richtet sich vorwiegend auch an Diagnostikerinnen und Diagnostiker. Die psychologische Diagnostik zielt darauf ab, Informationen regelgeleitet zu sammeln und zu verarbeiten. Anhand dessen sollen vorher festgelegte Fragestellungen bearbeitet und daraus Entscheidungen abgeleitet werden. Fragestellungen können die Beschreibung, Klassifikation, Erklärung, Prognose und Evaluation von Zuständen und/oder Verläufen umfassen. Die Entscheidungsfindung muss dabei wissenschaftlichen Kriterien und die Schlussfolgerung ethischen Standards entsprechen (Petermann & Eid, 2006). Diagnostische Aufgabenfelder und Fragestellungen sind in vielen psychologischen Anwendungsfächern relevant, unter anderem in der Arbeits- und Organisationspsychologie mit dem Ziel der Personalselektion, in der Pädagogischen Psychologie, zum Beispiel bei Schul- oder Studieneignungstests, in der Klinischen Psychologie bei der Diagnose psychischer Störungen und in der Markt- und Werbepsychologie, zum Beispiel bei der Diagnose der Wirkung eines Produktes auf Konsumenten (Schmidt-Atzert & Amelang, 2012). Ein weiteres Feld ist die Persönlichkeitspsychologie und die Diagnostik von Persönlichkeitsaspekten.

Der Autor setzt sich mit der Frage auseinander, ob und wie das Machine Learning im psychologisch-diagnostischen Prozess die Erkennung und Klassifikation von Krankheiten unterstützen und die Diagnostikerinnen und Diagnostiker entlasten kann. Als konkrete Anwendung wird das Thema *Mindful Machine Learning* näher beleuchtet. Dabei steht vor allem die aktuelle Forschung zur Anwendung des Machine Learnings in der psychologischen Diagnostik im Fokus.

Das Ziel dieser Hausarbeit ist es, aktuelle Forschungsarbeiten zu skizzieren, zu vergleichen und zu diskutieren.

Zunächst werden in Kapitel 2 die theoretischen Grundlagen der psychologischen Diagnostik wiederholt und kurz in die Theorien und Grundlagen des maschinellen Lernens sowie in die Achtsamkeitsforschung eingeführt. In Kapitel 3 wird der Themenschwerpunkt Machine Learning in der psychologischen Diagnostik vorgestellt und es werden aktuelle Arbeiten dieses

Themas skizziert, welche in Kapitel 4 reflektiert, diskutiert und miteinander verglichen werden. Zudem werden diese in den Gesamtkontext anderer Forschungsarbeiten über das maschinelle Lernen in der psychologischen Diagnostik eingebettet. Die Hausarbeit endet mit einem Fazit und einem Ausblick.

2 Theoretische Grundlagen

Dieses Kapitel stellt die Grundzüge der psychologischen Diagnostik, des Machine Learnings und der Achtsamkeitsmeditation vor.

2.1 Grundlagen psychologischer Diagnostik

Schmidt-Atzert und Amelang (2012) definieren und charakterisieren die psychologische Diagnostik als Methodenlehre im Kontext angewandter Psychologie. Mithilfe der Diagnostik sollen intra- und interindividuelle Merkmale von Personen, Unterschiede und Veränderungen im Verhalten und Erleben einschließlich relevanter Bedingungen exakt erfasst werden, sodass präzise Vorhersagen über zukünftiges Verhalten oder Erleben sowie von Veränderungen in definierten Situationen möglich sind.

Zum diagnostischen Prozess gehören laut Kubinger (2006) die Klärung der Fragestellung, die Auswahl diagnostischer Verfahren, die Anwendung und Auswertung der Verfahren, die Interpretation und Gutachtenerstellung sowie das Festsetzen der Intervention. Diverse Anforderungen werden an diesen Prozess gestellt. Vor allem soll die psychologische Diagnostik forschungsmethodische und testtheoretische Kriterien erfüllen, konkret also Objektivität, Reliabilität und Validität widerspiegeln (Moosbrugger & Kevala, 2012).

Hock und Krohne (2015) unterscheiden zur Beantwortung der Frage nach der Validität diagnostischer Urteile klinische beziehungsweise statistische Urteilsbildung und statistische Vorhersage. Die klinische Urteilsbildung beinhaltet intuitive, auf klinischem Erfahrungswissen basierende Informationsverarbeitung. Im Gegensatz dazu beschreiben die Autoren die statistische Urteilsbildung als eine Kombination und Gewichtung der Vorhersagevariablen anhand statistischer Beziehungen, die vorher empirisch ermittelt wurden. Formelle, statistische Methoden sind dabei der informellen klinischen Urteilsbildung möglichst vorzuziehen, oftmals ist aber eine Kombination des Vorgehens notwendig, weil häufig nur teilweise statistisch gesicherte Vorhersagemodelle vorliegen.

Der Autor dieser Hausarbeit fokussiert sich vorwiegend auf die Diagnostik im persönlichkeitspsychologischen und klinischen Kontext, er stellt in der Diskussion aber auch Querverbindungen zur Diagnostik in anderen psychologischen Anwendungsfächern her. Die wichtigsten Aufgaben der klinisch-psychologischen Diagnostik nach Fydrich (2012) sind zum einen die qualitative und quantitative Beschreibung der vorliegenden psychischen Störung und die

Klassifikation dieser mittels ICD und/oder DSM. Weiterhin sollen besonders lebensgeschichtlich relevante Bedingungen bei der Störungsentstehung und dem Verlauf herausgearbeitet werden. Während der Intervention soll der Verlauf beobachtet und die Veränderung der Symptomatik mittels adaptiver Diagnostik oder Verlaufsdiagnostik ermittelt werden. Am Ende ist die Überprüfung des Therapieerfolgs aus Qualitätssicherungsgründen essentiell.

2.2 Kurze Einführung in das Machine Learning

Machine Learning beschreibt die Fähigkeit eines Computers, Dinge und Inhalte zu lernen, ohne dass dabei explizit vorgegeben wird, wie dies zu tun ist. Es wird lediglich ein Rahmen abgesteckt, in welchem der jeweilige Algorithmus individuell auf die Input-Daten reagieren kann. Künstliche Intelligenz umfasst alle Techniken und Programme, die in irgendeiner Form menschliches Verhalten imitieren, sie beschränken sich somit nicht nur auf das reine Lernen. Machine Learning ist also lediglich ein Teilbereich der Künstlichen Intelligenz. Machine Learning lässt sich nochmals unterteilen in Supervised Learning, Unsupervised Learning und Reinforcement Learning. Bei Algorithmen aus der Kategorie Supervised Learning, also dem überwachten Lernen, sind bereits Daten und deren genaue Charakterisierung bekannt. Basierend auf diesen Daten passt die gewählte Methode ihre internen Parameter so an diesen Trainingsdatensatz an, dass diese Trainingsdaten möglichst genau abgebildet werden. Für unbekannte Daten liefert die Methode dann die passendste Charakterisierung. Ein Beispiel für einen Supervised Learning-Algorithmus sind *Support-Vector-Machines*. Diese Algorithmen basieren darauf, dass sie Eingabedaten als Vektoren in einem (hochdimensionalen) Vektorraum erkennen und diese durch Legen einer Hyperebene so trennen, dass diese möglichst eindeutig klassifiziert werden können (Bell, 2020).

Die Charakterisierung der Daten beim Unsupervised Learning ist nicht bekannt. Die Aufgabe der Methode ist es nun, die Daten in entsprechende Kategorien einzuteilen. Zu den Unsupervised Learning-Algorithmen gehört zum Beispiel der *k-Means*-Algorithmus (Bell, 2020).

Beim Reinforcement Learning, also dem bestärkenden Lernen, soll der Algorithmus eine Nutzenfunktion maximieren. Nach jeder Aktion erhält dieser ein Feedback über seine Handlung. Das Reinforcement Learning orientiert sich damit an dem natürlich beobachtbaren Lernverhalten (Sutton & Barto, 2020).

Ein weiterer und übergreifender Teilbereich des Machine Learning ist das Deep Learning, welches auf künstlichen neuronalen Netzen beruht. Diese orientieren sich am Aufbau des

menschlichen Gehirns und verknüpfen künstliche Neurone miteinander (Bell, 2020).

Fundamental baut Machine Learning stark auf mathematischen Grundlagen auf, beispielsweise auf der linearen Algebra, analytischen Geometrie, Vektoranalysis, Wahrscheinlichkeitsrechnung und Statistik sowie der stetigen Optimierung (Deisenroth, Faisal & Ong, 2020).

Aufgrund der schnellen Datenverarbeitung wird Machine Learning heutzutage in vielen Bereichen verwendet, unter anderem in der Psychologie. Der Einsatz von maschinellern Lernen und künstlicher Intelligenz eröffnet neue, vorher nicht dagewesene Möglichkeiten.

2.3 Einführung in die Achtsamkeit

Das Konzept der Achtsamkeitsmeditation wurde insbesondere populär durch Jon Kabat-Zinn. Achtsamkeitsmeditation ist neben der Konzentrationsmeditation eine von zwei Formen der Meditation, also einer aktiven Selbstregulation. Während der Fokus bei der Konzentrationsmeditation darauf liegt, die Aufmerksamkeit über einen längeren Zeitpunkt auf ein Detail zu legen, sei es ein Punkt, ein Objekt, ein Mantra oder der eigene Atem, geht es bei der Achtsamkeitsmeditation darum, das eigene verändernde Umfeld losgelöst, distanziert, zu betrachten. Man beginnt zwar damit, sich auf ein primäres Objekt, häufig den eigenen Atem, zu fokussieren, lässt dann aber zu, dass sich die Aufmerksamkeit schrittweise auf weitere Objekte ausdehnt. Nach einiger Zeit sollten so das gesamte physische Umfeld und alle gegenwärtigen körpereigenen Empfindungen, Gedanken, Erinnerungen, Emotionen und Fantasien Teil der Aufmerksamkeit sein. So simpel dieses Vorgehen scheinen mag, ist es tatsächlich herausfordernd. Ein Gedanke baut sich häufig aus und führt zu neuen Gedanken, Erinnerungen, Ideen, Meinungen oder Wünschen, was dazu führt, dass die ursprüngliche Aufmerksamkeit wieder nachlässt oder völlig verschwindet. Dieses Abschweifen wird in der Achtsamkeit aber nicht negativ gewertet, es ist einfach ein Objekt im Rahmen der Meditation. Sollte dies vorkommen, so wird dies zur Kenntnis genommen und die Aufmerksamkeit wieder auf den Atem gelenkt und das Ausdehnen des Bewusstseins kann von Neuem beginnen. Zudem ist wichtig, dass keinem Ereignis ein Wert beigemessen wird, alle Empfindungen werden gleich behandelt (Kabat-Zinn, 1982).

3 Aktuelle Machine Learning-Anwendungen

Im Folgenden werden die zwei Arbeiten über das Machine Learning in der psychologischen Diagnostik von Huys (2017) und Sauer et al. (2018) vorgestellt und es wird auf weitere Anwendungsmöglichkeiten eingegangen.

3.1 Computational Psychiatry

Die Übersichtsarbeit von Huys (2017) stellt die Forschungsrichtung *Computational Psychiatry* vor. *Computational Psychiatry* versucht, die theoretischen Fortschritte aus der Mathematik, insbesondere der Statistik, für die klinische Neurowissenschaften nutzbar zu machen. Die Nutzung modernerer Verfahren ist deshalb nötig, da diese im Vergleich zu den klassischen, älteren Methoden komplexe neurowissenschaftliche Prozesse besser modellieren können (Dayan & Abbott, 2001; MacKay, 2003).

Hier spielt das Machine Learning ebenfalls eine wichtige Rolle, da es sich sehr gut dafür eignet, Muster innerhalb großer und sehr komplexer Datensätze zu erkennen. Eine mögliche Anwendung ist die Auswertung und Modellierung intrapersoneller Prozesse bei psychiatrischen Erkrankungen (Huys, 2017). Da diese nur schwer objektiv zu beobachten und zu modellieren sind, sind die Behandelnden auf die Beschreibung und Erklärung der zu behandelnden Person angewiesen. Hier kommen Reinforcement Learning-Algorithmen ins Spiel, die durch Analyse versuchen, diese komplexen Prozesse zu quantifizieren und deren Funktionsweise zu beschreiben. Beispielsweise interagieren einige Hirnbereiche bei verschiedenen Denkprozessen miteinander, Neurotransmitter werden ausgeschüttet oder Hormone gebildet. Gleiche Prozesse können durchaus aber auch auf verschiedenen Substraten beruhen. Diese Methoden erlauben es nun auch, die Querverbindungen innerhalb des Systems zu schätzen (Huys, 2017). Dies liefert neue Erkenntnisse für bisher unbekannte Interaktionen in psychischen Prozessen.

Weitere mögliche Machine Learning-Anwendung ist die Prognose des Therapieerfolgs bei verschiedenen Krankheiten. Ein bereits recht früher Versuch mit klassischen Methoden wurde von Fu et al. (2008) unternommen. Die Autoren wollten prognostizieren, ob die kognitive Verhaltenstherapie bei an Depression Erkrankten einen Therapieerfolg erzielen wird. Hierfür nutzten sie magnetresonanztomographische Daten (MRT), die sie zu clustern versuchten.

Ähnliche Ansätze gibt es auch in der Diagnostik von anderen Krankheiten wie der Aufmerksamkeits-Defizit-Hyperaktivitäts-Störung (ADHS), Autismus, Demenz oder Schizophrenie, wobei die klassischen Ergebnisse nicht überzeugen können (Wolfers et al., 2015).

Huys (2017) beschreibt allerdings eine Ausnahme, die sehr gute Ergebnisse lieferte. Im Rahmen einer multizentrischen randomisierten Studie wurden an Depression Erkrankte randomisiert in zwei Untersuchungsbedingungen eingeteilt. Die erste Untersuchungsgruppe erhielt eine antidepressive Medikation basierend auf STAR*D. Die Medikamentengabe basiert insbesondere hierbei in einem ersten Schritt auf dem selektiven Serotonin-Wiederaufnahme-Inhibitor Citalopram. Sollte dieser nicht den gewünschten Therapieerfolg liefern, so wurde die Gabe mit weiteren Medikamenten ersetzt oder ergänzt (Rush et al., 2004). Die Personen innerhalb der zweiten Untersuchungsgruppe wurden mit einem Elektroenzephalogramm (EEG) untersucht. Mithilfe einer großen EEG-Datenbank wurden Personen ermittelt, die ähnliche EEGs aufwiesen. Die Probandinnen und Probanden in der Bedingung erhielten sodann diejenige Medikation, die bei den Personen mit ähnlichen EEGs zu guten Resultaten geführt hat. Es zeigte sich, dass diese Methode zu einem besseren Therapieerfolg führte als die Methode nach STAR*D (DeBattista et al., 2011). Im Gegensatz zu klassischen Methoden könnten in diesen Studien Machine Learning-Methoden aufgrund der beschriebenen Vorteile bei der Datenanalyse und der Therapieprognose helfen. Als klassische Methoden gelten zum Beispiel die multiple lineare Regression oder verallgemeinerte lineare Modelle.

Man muss anmerken, dass für eine zielgerichtete Verwendung des Machine Learning die Daten bereits aufbereitet werden sollten. Dies reduziert die Komplexität der Daten und führt zu besseren Ergebnissen. Die Aufbereitung basiert aber oft nicht auf psychologischem Wissen (Huys, 2017), sondern auf theoretisch-mathematischen Hintergründen, wobei es zu Problemen mit der tatsächlichen Aussagekraft kommen könnte. Dem könnte man allerdings entgegenwirken mit einer stärkeren Fundierung der innerpsychischen oder neurobiologischen Prozesse, das bedeutet, dass diese Daten bereits vor Anwendung der Machine Learning-Methoden mit psychologischen oder biologischen Modellen aufbereitet werden (Huys et al., 2017; Wiecki et al., 2015; Wiecki, Poland & Frank, 2015).

Huys (2017) folgert, dass die modernen mathematischen Methoden die Forschung im Feld der *Computational Psychiatry* zwar in großer Weise unterstützen kann, es aber bislang nur wenig klinische Anwendungen gibt.

3.2 Mindful Machine Learning

Im Folgenden soll eine Anwendung noch tiefer beschrieben werden. Dabei handelt es sich um das Forschungsfeld zum *Mindful Machine Learning*. Hierbei soll mithilfe von Machine Learning-Methoden prognostiziert werden, ob Personen Achtsamkeitsmeditation, kurz Achtsamkeit, betreiben.

Achtsamkeit ist schon länger Teil der psychologischen Forschung und es konnten viele positive Effekte von Achtsamkeit auf die Gesundheit entdeckt werden, zum Beispiel wirkt sie positiv im Hinblick auf Depressionen, Stress, Ängstlichkeit oder Persönlichkeitsstörungen. Neurodegenerative Erkrankungen werden durch Achtsamkeit ebenfalls vorgebeugt (Sauer et al., 2018). Machine Learning-Methoden können nun dabei helfen, die Achtsamkeit besser zu messen und damit die Forschung in diesem Feld voranzutreiben.

Die Autoren analysieren in ihrem Artikel konkret die prädiktive Validität von Items innerhalb eines Achtsamkeitsfragebogens. Sie widmen sich also der Frage, ob die Items die Achtsamkeit Praktizierenden vorhersagen können oder nicht.

Es werden zwei Stichproben mit einer Gesamtgröße von $N = 276$ untersucht und deren Ergebnisse gemeinsam berichtet. Für die Datenanalyse nutzen sie verschiedene Algorithmen und aggregieren die Ergebnisse am Ende, wie von Hastie, Tibshirani und Friedman (2009) vorgeschlagen. Die Analyse findet unter zwei Gesichtspunkten statt. Zum einen wird untersucht, ob die Items das Verhaltenskriterium *regelmäßige Achtsamkeitsmeditation* vorhersagen. Als Indikator für die psychometrische Qualität der Items nutzen die Autoren den Grad der korrekten Zuordnung. Zum anderen untersuchen die Autoren, ob die Machine Learning-Methoden tatsächlich die klassischen Methoden übertreffen. Als Testinstrument verwenden die Autoren die englischsprachige Kurzfassung des Freiburger Fragebogen zur Achtsamkeit, der sowohl Aufmerksamkeits- als auch emotionale Komponenten berücksichtigt. Das Instrument besteht aus 14 Items mit je vier Antwortoptionen und ist validiert mittels klassischer psychometrischer Methoden, zum Beispiel explorativer und konfirmatorischer Faktorenanalyse, aber auch durch die *Item-Response*-Theorie (Sauer et al., 2011). Achtsamkeit gilt hier als Persönlichkeitsaspekt, welcher in verschiedenen Situationen konsistent und über einige Zeit stabil ist.

Im Machine Learning kann es zur Überanpassung kommen. Das bedeutet, dass ein Modell zusätzliche irrelevante erklärende Variablen aufnimmt, was zu einer schlechteren Anpassungsgüte und schlechteren Schätzern führt. Dies kann man umgehen, indem man den Datensatz in Trainingsdatensatz und Testdatensatz aufteilt, wobei das Modell auf dem Trainingsda-

tensatz basiert und die Ergebnisse auf dem Testdatensatz (Hastie et al., 2009). Darauf aufbauend nutzen die Autoren ein wiederholtes k-faches Kreuzvalidierungsverfahren (Kuhn, 2008) für die Analyse der Daten.

Zusätzlich werden Sensitivität, die Rate der wahren positiven Zuordnungen, und die Spezifität, die Rate der wahren negativen Zuordnungen (Altman & Bland, 1994), sowie Cohens κ (Fleiss & Cohen, 1973) angegeben (Sauer et al., 2018).

Als Machine Learning-Modelle werden künstliche neuronale Netze (*neural networks*; nn), gewichtete Entscheidungsbäume (*boosted classification trees*; ada), Extrememlernmaschinen (*extreme learning machines*; elm), die stochastische Gradientenverstärkung (*stochastic gradient boosting machine*; gbm), die Nächste-Nachbarn-Klassifikation (*k-nearest neighbors*; knn), eine quadratische Diskriminanzanalyse (*quadratic discriminant analysis*; qda), *Random Forests* (rf), eine *Support-Vector-Machine* mit linearem Kern (svmlinear) und eine *Support-Vector-Machine* mit polynomialem Kern (svmpoly) verwendet. Als Vergleichsmodell dient ein verallgemeinertes lineares Modell, genauer die logistische Regression (Sauer et al., 2018).

Über alle zehn Modelle war die Sensitivität gut ($\bar{x} = 76\%$; $m = 81\%$; $SD = 24\%$) und die Spezifität akzeptabel ($\bar{x} = 67\%$; $m = 70\%$; $SD = 23\%$) gegenüber einer Baseline von 60%. Die Streubreite der Ergebnisse zwischen den Algorithmen ist hoch. Die mit Abstand besten Ergebnisse lieferte der Algorithmus *Random Forest*, ein Supervised Learning-Ansatz mit Sensitivität von 99% und Spezifität von 100%, die schlechtesten Ergebnisse der, ebenfalls aus dem Bereich des Supervised Learning stammende, gewichtete Entscheidungsbäume-Algorithmus, der als einziger Algorithmus sowohl bei der Sensitivität als auch bei der Spezifität unterhalb des Vergleichsmodells bleibt. Bei der Spezifität bleibt einzig noch der *extreme learning machines*-Algorithmus unterhalb des Vergleichswerts. Alle weiteren Algorithmen zeigen bessere Ergebnisse als die logistische Regression.

Die Autoren folgern, dass die Nutzung von Machine Learning-Algorithmen einen Vorteil gegenüber klassischen Modellen liefert, wobei hier nicht alle Algorithmen gleich gute Ergebnisse zeigen. Im Hinblick auf die Items im Fragebogen waren die Fragen 2, 3, 8, 10 und 12 die wichtigsten für die Analyse der Achtsamkeit und die Items 1, 5 und 14 ließen die stärkste Diskrepanz zwischen beiden Gruppen erkennen.

Sauer et al. (2018) schließen, dass man mithilfe der verwendeten Version des Freiburger Fragebogen zur Achtsamkeit feststellen kann, ob eine Person Achtsamkeit betreibt oder nicht. Die verwendeten Machine Learning-Algorithmen übertreffen weitgehend die in der Psychologie klassischerweise verwendete logistische Regression (Cohen, Cohen, West & Aiken, 2002)

bei der Genauigkeit der Vorhersage. Die Verwendung von mehreren Methoden führt zudem zu stabileren Ergebnissen und wird daher empfohlen. Probleme sehen die Autoren darin, dass die Quantität und Qualität des Achtsamkeitstraining nicht unterschieden wurden. Die weitere Aufschlüsselung, wie häufig die Probandinnen und Probanden Achtsamkeit betreiben und in welcher Art, würde womöglich deutlichere Ergebnisse liefern. Sie schlussfolgern, dass Machine Learning-Methoden nützlich sind, um die Validität von Instrumenten zu messen (Sauer et al., 2018).

3.3 Weitere Anwendungen in der psychologischen Diagnostik

Machine Learning-Methoden finden sich auch bei der Diagnostik in anderen Anwendungsfächern, zum Beispiel in der Pädagogischen Psychologie bei der Frage nach der Studieneignung (Assiri et al., 2022) oder innerhalb der Arbeits- und Organisationspsychologie zum Thema Personaldiagnostik (Ock & An, 2021). Die Ergebnisse sind ebenfalls durchaus vielversprechend. Assiri et al. (2022) finden bei der Studieneignung eine Vorhersagegenauigkeit von 75% für *Support-Vector-Machines*, von 81% für Entscheidungsbäume und 91% für künstliche neuronale Netze. Auch bezüglich der Personaldiagnostik sind die Ergebnisse akzeptabel (Ock & An, 2021).

Eine weitere Fragestellung, bei der Machine Learning-Algorithmen verwendet werden, ist die Diagnostik innerhalb der Markt- und Werbepsychologie, wenn es um die Wirkung eines Produktes auf Konsumenten geht. Die Ergebnisse deuten darauf hin, dass Machine Learning-Methoden im digitalen Marketing bessere Leistungen erbringen als bestehende Praktiken (Ullal et al., 2021).

Machine Learning wird auch angewandt bei der Spracherkennung (Mitchell, 2006) oder Handschriftenerkennung, was beispielsweise innerhalb der Forensischen Psychologie interessant ist und genutzt werden könnte (Tortora et al., 2020, Spivak & Shepherd, 2020).

Weiteres Anwendungsfeld ist die Molekulare Psychologie bei der Genexpression in der Zelle (Mitchell, 2006; Xu & Jackson, 2019), wobei Machine Learning auch hier gute Ergebnisse liefert, konkret bei der Vorhersage von diffusen großzelligen B-Zell-Lymphomen (Shipp et al., 2002) .

4 Diskussion und Reflexion

Abschließend werden die vorgestellten Artikel diskutiert und im Hinblick auf deren Relevanz und Erkenntnis eingebettet. Des Weiteren werden neue Forschungsergebnisse des Feldes skizziert.

4.1.1 Diskussion der Primärartikel

Beide Artikel zeigen, dass Machine Learning spannende neue Möglichkeiten für die Psychologie, insbesondere in der Diagnostik bieten (Huys, 2017; Sauer et al., 2018).

4.1.1.1 *Computational Psychiatry*

Huys (2017) beschreibt mögliche klinisch-diagnostische Anwendungsfelder für Machine Learning. An dieser Stelle soll darauf eingegangen werden, wie weit der aktuelle Forschungsstand in diesem Feld ist.

Ein vorgestelltes Forschungsgebiet ist die Modellierung komplexer neuronaler Prozesse. Mithilfe von Deep Learning und künstlichen neuronalen Netzen kann die neuronale Aktivität vorhergesagt und so die neuropsychologische Diagnostik unterstützt werden. Papadimitriou et al. (2020) entwickelten ein Modell, von ihnen *Assembly Calculus* genannt, basierend auf neuronalen Verknüpfungen, den sogenannten *Assemblies*. *Assemblies* sind zufällig miteinander interagierende exzitatorische Neuronen, von denen angenommen wird, dass sie beispielsweise für Erinnerungen verantwortlich sind. Das Modell zielt darauf ab, das Zusammenspiel der Neuronen zu modellieren und daraufhin Aussagen über kognitive Prozesse zu treffen. Das analytische Modell wurde in der Anwendung mithilfe von Simulationen gestützt und in ein künstliches neuronales Netz eingebettet. Es zeigt sich, dass das Modell zu vergleichbaren Schlussfolgerungen führt wie klassische Methoden und im Einklang mit bestehenden Forschungsergebnissen steht.

Einen ähnlichen Ansatz nutzen auch Wang et al. (2022). Die Autoren versuchen, Simulationen innerhalb des Hodgkin-Huxley-Modells (Hodgkin & Huxley, 1952) auszuführen. Das Hodgkin-Huxley-Modell ist das bekannteste Modell für die Simulation neuronaler Aktivität. Um eine bestehende Forschungslücke bei der Berechnung der Aktionspotentiale feuender Neuronen zu schließen, nutzen die Autoren ein Vorhersagemodell auf Grundlage künstlicher

neuronaler Netze, das sogenannte *Feature Prediction Module*, welches Eigenschaften der Aktionspotentiale wie maximale und minimale Spannung schätzen soll. Die Ergebnisse der Analyse zeigen, dass die Kombination aus bestehendem Modell und dem *Feature Prediction Module* die Aktionspotentiale der Hodgkin-Huxley-Neuronen mit hoher Genauigkeit vorhersagen kann.

Während in der Studie von Fu et al. (2008) keine Machine Learning-Methoden verwendet wurden, nutzt eine neuere Studie einen Supervised Machine Learning-Algorithmus zur Erfolgsprognose der kognitiven Verhaltenstherapie bei an Depression Erkrankten basierend auf MRT-Daten. Die Ergebnisse zeigen, dass die Klassifikation mit einer Genauigkeit von 83% erfolgt, in diesem Anteil an Fällen erfolgte also tatsächlich eine Reduktion der depressiven Symptome (Tymofiyeva et al., 2019).

Aufgezählt wurden weitere mögliche Anwendungen innerhalb der Diagnostik von Krankheiten, konkret die Diagnostik von Schizophrenie, Autismus, Demenz und ADHS (Huys 2017). In diesen Feldern gibt es ebenfalls Fortschritte und neuere Forschungsarbeiten.

Innerhalb einer Übersichtsarbeit (Cortes-Briones et al., 2021) werden 24 Studien zur Nutzung von Machine Learning-Algorithmen in der Schizophrenie-Diagnostik beschrieben. Die Anwendung erstreckt sich dabei auf verschiedene Analysedaten. Eine Studie nutzt kombinierte Daten aus funktioneller MRT und Genomanalysen, eine weitere aus funktioneller und struktureller MRT, 13 Studien nutzen lediglich funktionelle MRT-Daten, vier Studien wiederum strukturelle MRT-Daten. Genomdaten wurden nur von zwei Studien genutzt, ebenso wie EEG-Daten. Eine einzige Arbeit nutzt Audioaufnahmen von Interviews. Innerhalb all dieser Studien wurden auch verschiedenste Machine Learning-Algorithmen benutzt, wobei die meisten dieser, nämlich 17, auf künstlichen neuronalen Netzen beruhen. In drei Studien wurden *Support-Vector-Machines* innerhalb des Supervised Learnings benutzt und eine Arbeit nutzt einen Unsupervised Learning-Algorithmus (*fully-connected generative adversarial network*). Die Studien, die künstliche neuronale Netze für die Schizophrenie-Diagnostik verwenden, weisen eine große Spannweite an Genauigkeit auf (Genauigkeit zwischen 63% und 98%), wobei die durchschnittliche Genauigkeit für die Klassifizierung basierend auf den neuronalen Bildgebungsverfahren bei circa 90% liegt. Studien, die genetische Daten nutzen, erreichen mit Machine Learning-Modellen mindestens dieselbe Genauigkeit wie herkömmliche Methoden (72,1% beziehungsweise 73,6% Genauigkeit). Die Studie mit audiobasierten Daten, die eine Kombination aus künstlichen neuronalen Netzen und einem *Random Forest*-Algorithmus nutzte, erzielt eine relativ hohe Genauigkeit von 74,4%. Weiterhin lassen sich mithilfe dieser

und ähnlicher Machine Learning-gestützter Methoden auch bei der Prognose von Psychosen bei an Schizophrenie Erkrankten gute Ergebnisse feststellen (Genauigkeit zwischen 67% und 93,9%).

Ein weiterer Review präsentiert Machine Learning-Verfahren in der Autismusdiagnostik (Eslami et al., 2021). In dieser Arbeit werden 49 Studien vorgestellt. Diese Studien nutzen allesamt Daten bildgebender Verfahren, funktioneller und/oder struktureller MRT, die sie mithilfe von Machine Learning auswerten. Das Mittel der Wahl sind dabei hauptsächlich *Support-Vector-Machines* oder künstliche neuronale Netze. Die Genauigkeit der Prognose beläuft sich auf eine Spannweite von 52% bis 98,67%. 36 der 49 Studien erreichen eine Genauigkeit von mindestens 70%.

Ähnliche Resultate finden sich auch bei der Demenzdiagnostik (Grueso & Viejo-Sobera, 2021). Als Untersuchungsdaten dienen erneut Daten aus der Neurobildgebung, dabei insbesondere MRT, die Positronen-Emissions-Tomografie (PET) und Daten der Magnetoencephalographie (MEG). Die Stichprobengröße variiert zwischen den Studien stark, die kleinste Stichprobe umfasst lediglich 27 Personen, die größte Stichprobe 3.940 Personen. Die beliebtesten Machine Learning-Methoden, die für die Klassifikation verwendet werden, basieren erneut auf *Support-Vector-Machines* (60 von 116 Studien). Die Genauigkeit der Klassifikation bei MRT-Daten beträgt 74,5% gegenüber 76,9% bei PET-Daten. Die Genauigkeit kann noch verbessert werden, wenn beide bildgebenden Verfahren miteinander kombiniert werden. Die Kombination führt dann zu einer mittleren Genauigkeit von 77,5%. Eine Studie erreichte bei der Verwendung von MRT- und MEG-Daten sogar eine Genauigkeit von 100%, zwei weitere Studien mit MEG-Daten Genauigkeiten von 87% beziehungsweise ebenfalls 100%. Das schlechteste Ergebnis wurde mit einer Genauigkeit von 50% erzielt. Aggregiert erzielen *Support-Vector-Machines* eine mittlere Genauigkeit von 75,4% und künstliche neuronale Netzwerke eine mittlere Genauigkeit von 78,5%.

Auch die Erkennung von ADHS wird durch Machine Learning-Verfahren unterstützt. Die genutzten Daten basieren dabei ebenfalls auf bildgebenden Verfahren (funktionelles MRT und/oder strukturelles MRT), wie ein Review über 26 Studien zeigt (Eslami et al., 2021). Großteils werden ebenfalls *Support-Vector-Machines* oder künstliche neuronale Netze als Analysemodell verwendet. *Support-Vector-Machines* erzielen innerhalb von zwölf Studien eine Genauigkeit zwischen 59% und 94,9% und künstliche neuronale Netze innerhalb von neun Studien zwischen 58% und 90,3%. Weitere Machine Learning-Algorithmen (*Gaussian Process Classifier*, Entscheidungsbäume und Extremlernmaschinen) gelangen zu einer Vorhersagegenauigkeit zwischen 60,78% und 90,18%.

Abweichend von dem bisher Beschriebenen nutzen Das und Khanna (2021) für die Autismusdiagnostik *Support-Vector-Machines*, mit deren Hilfe sie die Dynamik der Pupillengröße analysieren. Die Dynamik der Pupillengröße stellt einen objektiven Biomarker für die ADHS-Erkennung dar. Das Ergebnis zeigt eine Sensitivität von 77,3% und eine Spezifität von 75,3%.

Zusammenfassend lässt sich feststellen, dass Machine Learning-Methoden im klinisch-diagnostischen Bereich häufig in Verbindung mit bildgebenden Verfahren verwendet werden. In den beschriebenen Anwendungsfeldern zeigen diese Methoden mindestens vergleichbare Ergebnisse gegenüber herkömmlichen und klassischen mathematisch-statistischen Verfahren wie verallgemeinerten linearen Modellen. Die Modelle, die auf künstlichen neuronalen Netzen beruhen, erzielen im Durchschnitt eine etwas höhere Genauigkeit als andere Machine Learning-Modelle wie beispielsweise *Support-Vector-Machines*.

Die Ergebnisse wirken ohne Einordnung gut und vielversprechend (Cortes-Briones et al., 2021), müssen aber kritisch betrachtet werden. Eine Einordnung in einen größeren Kontext folgt in Kapitel 4.1.2.

4.1.1.2 *Mindful Machine Learning*

Die Ergebnisse der Arbeit von Sauer et al. (2018) im Hinblick auf die Vorhersagegenauigkeit der Machine Learning-Algorithmen liegen im Durchschnitt der vorgestellten klinisch-diagnostischen Arbeiten. Die Anzahl der Studien im Feld des *Mindful Machine Learning* ist noch sehr gering, weshalb bis zum heutigen Tag keine neuen Untersuchungen berichtet werden können.

Weitere Studien, die Machine Learning im Rahmen der persönlichkeitspsychologischen Diagnostik untersuchen, erreichen allerdings ebenfalls ähnliche Ergebnisse (Lübke, 2020). Es lassen sich mit Machine Learning-Ansätzen nicht nur individuelle Persönlichkeitseigenschaften wie die Big Five vorhersagen. Wie in der Arbeit von Sauer et al. (2018) zudem gezeigt, lassen sich auch methodische Fragestellungen untersuchen. Im Allgemeinen ist dies für die psychologische Diagnostik sehr interessant, um die einzelnen Items eines Instruments und deren Effektstärken zu prüfen. So kann man die Komplexität und Größe von Fragebögen reduzieren oder diese entsprechend überarbeiten (Sauer et al., 2018). Eine dritte Machine Learning-Anwendung innerhalb des persönlichkeitspsychologischen-diagnostischen Feldes ist die Personalisierung von Produkten und Dienstleistungen durch Empfehlungen (Stachl et al., 2020).

4.1.1.3 Zusammenfassung

Beide Artikel zeigen verschiedene Anwendungsfelder des Machine Learnings innerhalb der psychologischen Diagnostik. Die Machine Learning-Algorithmen werden häufig auf Daten bildgebender Verfahren angewandt. Am besten schnitten dabei Methoden basierend auf *Support-Vector-Machines* und künstlichen neuronalen Netzen ab. Die Ergebnisse übertreffen bis auf wenige Ausnahmen die Ergebnisse klassischer Analysen wie der linearen Regressionsanalyse oder der verallgemeinerten linearen Modelle.

4.1.2 Diagnostische Einordnung des Machine Learning

Es handelt sich bei Machine Learning in der psychologischen Diagnostik zwar um ein recht kleines, aber sehr spannendes, vielversprechendes und stetig wachsendes Forschungsfeld. Auch wenn die Ergebnisse sehr für die Nutzung von Machine Learning-Methoden sprechen, müssen diese kritisch hinterfragt und vor dem Hintergrund diagnostischer Gütekriterien eingeordnet werden.

Machine Learning-Methoden sind für das Ziel der psychologischen Diagnostik, die Erfassung intra- und interindividueller Merkmale von Personen und die Prognose über zukünftiges Verhalten (Schmidt-Atzert & Amelang, 2012) förderlich, da sie, wie dargelegt, die Klassifizierung von Erkrankungen beispielsweise verbessern.

Fraglich ist, inwiefern die Anforderungen der regelgeleiteten Informationsverarbeitung (Petermann & Eid, 2006) durch die Machine Learning-Methoden erfüllt werden. Zwar handelt es sich bei den Methoden um Algorithmen, also um deterministische und wohldefinierte Vorschriften, die somit regelgeleitet Ergebnisse produzieren. Dennoch sind diese in den meisten Fällen als Black-Box zu verstehen (Cortes-Briones et al., 2021). Obwohl es bereits Möglichkeiten gibt, Machine Learning ohne konkreten Machine Learning-Hintergrund auszuführen (zum Beispiel mithilfe des R-Pakets *caret*; Sauer et al., 2018), fehlt häufig dennoch das Verständnis über die theoretischen Hintergründe, die Verarbeitung durch den Algorithmus oder über mögliche Probleme bei der Interpretation der Ergebnisse. Ein konkretes Beispiel sind künstliche neuronale Netze, die Tausende oder Millionen an Eingabedaten verarbeiten und nicht-linear transformieren. Künstliche neuronale Netze sind zudem, ähnlich wie das menschliche Nervensystem, so verknüpft, dass Cluster von Neuronen gemeinsame Aufgaben erfüllen und jedes Neuron Teil vieler Neuronencluster ist (Roy, 2012). Dies macht es schwer, die Vorgehensweise zu erklären, was ein Nachteil gegenüber den einfach zu erklärenden linearen Modellen ist. Eine Folge des fehlenden Verständnisses könnte sein, dass Diagnostikerinnen und

Diagnostiker zögern, den Ergebnissen der Machine Learning-Algorithmen zu vertrauen (Lipton, 2018). Dem bei der Entwicklung der Methoden entgegenzuwirken, ist schwierig, da es aktuell kaum möglich ist, künstliche neuronale Netze so zu gestalten, dass sie einerseits transparent sind und andererseits auch genau so leistungsfähig (Cortes-Briones et al., 2021), beispielsweise durch Reduktion der Variablen. Eine Lösung dafür bieten aber Post-hoc-Methoden, die aussagen können, welche Variablen das Ergebnis des künstlichen neuronalen Netzes am meisten beeinflusst hat. Diese Methoden liefern zwar keine Begründung oder Rechtfertigung für das Ergebnis, aber können Diagnostikerinnen und Diagnostikern beschreiben, welche Eingabevariablen am relevantesten waren. So können Forschung und Anwendung weiter vorangetrieben werden. Allerdings ist hier auch Vorsicht geboten, da einige der Post-hoc-Methoden erhebliche Einschränkungen aufweisen, zum Beispiel bei der Schizophrenie-Diagnostik (Cortes-Briones et al., 2021). Um die komplexe Methodik hinter den künstlich neuronalen Netzen zu verstehen, reichen diese Methoden bislang aber noch nicht aus (Darwiche, 2018).

Es wurde bereits kurz skizziert, dass die Forschungsergebnisse eventuell nicht die Gütekriterien quantitativer Forschung, Objektivität, Reliabilität und Validität (Moosbrugger & Kevala, 2012) erfüllen. Während Arbeiten darlegen, dass die Machine Learning-Ansätze eine hohe Genauigkeit im Vergleich zu den klassischen Methoden aufweisen (Cortes-Briones et al., 2021, Tymofiyeva et al., 2019, Wang et al., 2022), ist es ungewiss, inwieweit die Ergebnisse replizierbar und reliabel (Orrù et al., 2020) und valide sind. Dies lässt sich dadurch begründen, dass die Ergebnisse aufgrund geringer Stichproben überschätzt werden können. Untersuchungen untermauern, dass Modelle, die mit größeren Datensätzen getestet werden, geringere Genauigkeiten aufweisen (Yan et al., 2019; Yang et al., 2019; Zeng et al., 2018; Zhao et al., 2020). Das lässt auf eine geringere konvergente Validität (Moosbrugger & Kevala, 2012) hindeuten. Fraglich ist deshalb auch, ob die Ergebnisse auf größere Stichproben übertragbar sind, beziehungsweise inwiefern die Algorithmen auf andere Trainingsdatensätze reagieren und wie sehr diese das Ergebnis beeinflussen, also ob externe Validität gegeben ist. Zudem sind die verwendeten Datensätze, Trainingsdatensatz und Testdatensatz, in den meisten Studien nicht voneinander unabhängig, was ebenfalls nicht für Validität spricht (Cortes-Briones et al., 2021). Dem könnte man durch die Kombination verschiedener Machine Learning-Verfahren entgegenwirken. Die Kombination würde es ermöglichen, die Überanpassung zu vermeiden und dazu führen, dass das Modell besser auf verschiedenste Daten verallgemeinert werden kann (Grueso & Viejo-Sobera, 2021). Empfehlenswert wäre zudem, eine möglichst große und repräsentative Datengrundlage zu nutzen. Aktuelle Deep Learning-Modelle nutzen beispielsweise Einhunderttausend bis Einhundertmillionen Datenpunkte innerhalb der Trainingsdaten (Devlin et al.,

2018). Eine solche Zahl an Daten ist aber innerhalb der psychologischen Diagnostik aktuell nicht denkbar. Doch auch hier gibt es Lösungsansätze, die Größe der Datensätze zu erhöhen. Eine Möglichkeit ist, die Datensätze durch künstliche Daten zu ergänzen, beispielsweise durch Simulation oder durch geschicktes Modifizieren realer Daten (Lashgari et al., 2020; Shorten und Khoshgoftaar, 2019). Das Problem geringer Reliabilität und Validität würde durch das künstliche Erzeugen von Daten aber potentiell weiterhin bestehen. Eine weitere Option wäre die Aufnahme multimodaler Daten in die Modelle. Das führt zu Leistungsverbesserungen und weist den Vorteil auf, dass die Modelle auch nur mit partiellen Daten trainiert werden können (Guo et al., 2019).

Hock und Krohne (2015) argumentieren dafür, dass formelle, statistische Methoden der informellen klinischen Urteilsbildung möglichst vorzuziehen sind. Es stellt sich die Frage, wie Machine Learning-Algorithmen zu werten sind und ob diese den klassischen statistischen Methoden gleichgesetzt werden sollten. Das ist aufgrund der Ungewissheit bei der Modellbeschreibung und der hohen Abstraktion bedenklich. Die Machine Learning-Verfahren sind in ihrer heutigen Form kein Ersatz für eine klinische Urteilsbildung. Es empfiehlt sich weiterhin ein kombiniertes Vorgehen aus klinischer und statistischer Urteilsbildung.

Kontrovers diskutiert werden auch die ethischen Aspekte des Machine Learnings. Nach Petermann und Eid (2006) muss die diagnostische Entscheidungsfindung auf ethischen Grundlagen basieren. Inwiefern diese aber hier erfüllt werden, ist fraglich. Zum einen benötigen Machine Learning-Methoden, wie beschrieben, eine Vielzahl an, optimalerweise leicht zugänglichen, Daten (Cortes-Briones et al., 2021), für eine entsprechende Prognose. Dies steht aber in Konflikt mit dem zunehmenden Bestreben nach mehr Datenschutz. Hier müssen die privaten Interessen nach informationeller Selbstbestimmung gegenüber den wissenschaftlichen Erkenntnissen und möglichen sozialen Fortschritten abgewägt werden (Mitchell, 2006). Zum anderen dürfen keine Personengruppen, beispielsweise an Schizophrenie Erkrankte, bei Erhebungen diskriminiert werden (Cortes-Briones et al., 2021). Es kann nicht ausgeschlossen werden, dass Datensätze immer repräsentativ für eine ganze Bevölkerung sind. In einer Studie über die Gehirnkonnektivität bei an Schizophrenie Erkrankten befanden sich hauptsächlich Daten männlicher Personen. Die verwendeten künstlichen neuronalen Netze, die für die Mustererkennung dienlich sind, wurden nun auf diese vorwiegend männlichen Daten trainiert, was das Risiko einer Fehldiagnostik bei weiblichen Personen erhöht und zu falschen Charakterisierungen führen kann. In Anbetracht dessen, welche negativen Auswirkungen eine Fehldiagnose für eine Person nach sich ziehen kann, müssen die Algorithmen gewisse ethische Standards erfüllen. Zu ähnlichen Effekten könnten es bei verzerrten Daten im Hinblick auf Rasse, Gesellschaftsklassen

oder ähnlichen Attributen kommen. Entsprechend sollten die Algorithmen angepasst werden, damit diese Diskriminierung reduziert wird (Cortes-Briones et al., 2021). Ethisch problematisch ist außerdem, dass die in der psychologischen Diagnostik erfolgreichen Algorithmen, für andere Zwecke missbraucht werden könnten (Cortes-Briones et al., 2021). Denkbar wäre zum Beispiel die militärische Nutzung der Algorithmen.

Bezogen auf die lange Wartezeit für Plätze in Richtlinienpsychotherapie versprechen diese Methoden aber eine Entlastung des Gesundheitswesens und die Umsetzung effektiverer Behandlungsinterventionen (Cortes-Briones et al., 2021).

5 Fazit und Ausblick

Die Popularität von Machine Learning-Methoden innerhalb der psychologischen Diagnostik ist in den letzten Jahren stark gestiegen. Es gibt kaum ein Anwendungsfeld, das nicht bereits mit Machine Learning-Algorithmen untersucht wurde. Die zunehmende Datenflut unterstützt diesen Prozess nochmals.

Diese Verfahren können die Diagnostikerin und den Diagnostiker unterstützen. Sie liefern bessere Ergebnisse zum Beispiel bei der Klassifikation psychischer Krankheiten als herkömmliche Analysemethoden.

Wichtig ist, dass diese Methoden kein Allheilmittel darstellen und diese nicht blind angewandt werden dürfen. Insbesondere müssen die psychologischen Gütekriterien überwacht und ethische Fragestellungen kritisch hinterfragt werden. Die Nutzung von Machine Learning erfordert also eine aktive Diagnostikerin beziehungsweise einen aktiven Diagnostiker, die die Ergebnisse kritisch einordnen können.

Die Forschung in diesem Feld steht noch ziemlich am Anfang und wird in Zukunft sicher intensiviert werden.

Referenzen

- Altman, D. G. & Bland, J. M. (1994). Statistics Notes: Diagnostic tests 1: sensitivity and specificity. *BMJ*, 308(6943). <https://doi.org/10.1136/bmj.308.6943.1552>
- Assiri, B., Bashraheel, M. & Alsuri, A. (2022). Improve the Accuracy of Students Admission at Universities Using Machine Learning Techniques. *2022 7th International Conference on Data Science and Machine Learning Applications (CDMA)*. <https://doi.org/10.1109/cdma54072.2022.00026>
- Bell, J. (2020). *Machine Learning*. Wiley.
- Bundespsychotherapeutenkammer. (2018). *Ein Jahr nach der Reform der Psychotherapie-Richtlinie*. https://www.bptk.de/wp-content/uploads/2019/01/20180411_bptk_studie_wartezeiten_2018.pdf
- Cohen, J., Cohen, P., West, S. G. & Aiken, L. S. (2002). *Applied Multiple Regression/Correlation Analysis for the Behavioral Sciences* (3 Aufl.). Taylor & Francis Ltd. <https://doi.org/10.4324/9780203774441>
- Cortes-Briones, J. A., Tapia-Rivas, N. I., D’Souza, D. C. & Estevez, P. A. (2021). Going deep into schizophrenia with artificial intelligence. *Schizophrenia Research*. <https://doi.org/10.1016/j.schres.2021.05.018>
- Darwiche, A. (2018). Human-level intelligence or animal-like abilities? *Communications of the ACM*, 61(10), 56–67. <https://doi.org/10.1145/3271625>
- Das, W. & Khanna, S. (2021). A Robust Machine Learning Based Framework for the Automated Detection of ADHD Using Pupillometric Biomarkers and Time Series Analysis. *Scientific Reports*, 11(1). <https://doi.org/10.1038/s41598-021-95673-5>
- Dayan, P. & Abbott, L. F. (2001). *Theoretical Neuroscience*. MIT Press.

- DeBattista, C., Kinrys, G., Hoffman, D., Goldstein, C., Zajecka, J., Kocsis, J., Teicher, M., Potkin, S., Preda, A., Multani, G., Brandt, L., Schiller, M., Iosifescu, D. & Fava, M. (2011). The use of referenced-EEG (rEEG) in assisting medication selection for the treatment of depression. *Journal of Psychiatric Research*, 45(1), 64–75. <https://doi.org/10.1016/j.jpsychires.2010.05.009>
- Deisenroth, M. P., Faisal, A. A. & Ong, C. S. (2020). *Mathematics for Machine Learning*. Cambridge University Press.
- Devlin, J., Chang, M. W., Lee, K. & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of the 2019 Conference of the North*. <https://doi.org/10.18653/v1/n19-1423>
- Eslami, T., Almuqhim, F., Raiker, J. S. & Saeed, F. (2021). Machine Learning Methods for Diagnosing Autism Spectrum Disorder and Attention- Deficit/Hyperactivity Disorder Using Functional and Structural MRI: A Survey. *Frontiers in Neuroinformatics*, 14. <https://doi.org/10.3389/fninf.2020.575999>
- Fleiss, J. L. & Cohen, J. (1973). The Equivalence of Weighted Kappa and the Intraclass Correlation Coefficient as Measures of Reliability. *Educational and Psychological Measurement*, 33(3), 613–619. <https://doi.org/10.1177/001316447303300309>
- Fu, C. H., Williams, S. C., Cleare, A. J., Scott, J., Mitterschiffthaler, M. T., Walsh, N. D., Donaldson, C., Suckling, J., Andrew, C., Steiner, H. & Murray, R. M. (2008). Neural Responses to Sad Facial Expressions in Major Depression Following Cognitive Behavioral Therapy. *Biological Psychiatry*, 64(6), 505–512. <https://doi.org/10.1016/j.biopsych.2008.04.033>
- Fydrich, T. (2012). Diagnostik in der Klinischen Psychologie. In *Psychologische Diagnostik. Springer-Lehrbuch*. (S. 503–535). Springer. https://doi.org/10.1007/978-3-642-17001-0_10

- Grueso, S. & Viejo-Sobera, R. (2021). Machine learning methods for predicting progression from mild cognitive impairment to Alzheimer's disease dementia: a systematic review. *Alzheimer's Research & Therapy*, 13(1). <https://doi.org/10.1186/s13195-021-00900-w>
- Guo, W., Wang, J. & Wang, S. (2019). Deep Multimodal Representation Learning: A Survey. *IEEE Access*, 7, 63373–63394. <https://doi.org/10.1109/access.2019.2916887>
- Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning* [E-Book]. Springer. <https://doi.org/10.1007/978-0-387-84858-7>
- Hock, M. & Krohne, H. W. (2015). *Psychologische Diagnostik*. Kohlhammer.
- Hodgkin, A. L. & Huxley, A. F. (1952). A quantitative description of membrane current and its application to conduction and excitation in nerve. *The Journal of Physiology*, 117(4), 500–544. <https://doi.org/10.1113/jphysiol.1952.sp004764>
- Huys, Q. J. M. (2017). Computational Psychiatry. *Zeitschrift für Psychiatrie, Psychologie und Psychotherapie*, 65(1), 21–26. <https://doi.org/10.1024/1661-4747/a000297>
- Kabat-Zinn, J. (1982). An outpatient program in behavioral medicine for chronic pain patients based on the practice of mindfulness meditation: Theoretical considerations and preliminary results. *General Hospital Psychiatry*, 4(1), 33–47. [https://doi.org/10.1016/0163-8343\(82\)90026-3](https://doi.org/10.1016/0163-8343(82)90026-3)
- Kubinger, K. D. (2006). *Psychologische Diagnostik*. Hogrefe.
- Kuhn, M. (2008). Building Predictive Models in R Using the caret Package. *Journal of Statistical Software*, 28(5). <https://doi.org/10.18637/jss.v028.i05>
- Lashgari, E., Liang, D. & Maoz, U. (2020). Data augmentation for deep-learning-based electroencephalography. *Journal of Neuroscience Methods*, 346, 108885. <https://doi.org/10.1016/j.jneumeth.2020.108885>

- Lipton, Z. C. (2018). The Mythos of Model Interpretability. *Queue*, 16(3), 31–57. <https://doi.org/10.1145/3236386.3241340>
- Lübke, R. (2020). *Zwischen Tradition und Moderne: Machine Learning in der Persönlichkeitsmessung [Dissertation]*. <https://doi.org/10.5282/edoc.26125>
- MacKay, J. C., MacKay, V. J. C., Kay, M. D. J. C. & Cambridge University Press. (2003). *Information Theory, Inference and Learning Algorithms*. Cambridge University Press.
- Mitchell, T. M. (2006). *The Discipline of Machine Learning*. <http://www.cs.cmu.edu/~tom/pubs/MachineLearning.pdf>
- Moosbrugger, H. & Kelava, A. (2012). *Testtheorie und Fragebogenkonstruktion: Mit Online-Materialien (Springer-Lehrbuch)* (2., aktual. u. überarb. Aufl.). Springer.
- Ock, J. & An, H. (2021). Machine Learning Approach to Personality Assessment and Its Application to Personnel Selection. *Korean Journal of Industrial and Organizational Psychology*, 34(2), 213–236. <https://doi.org/10.24230/kjiop.v34i2.213-236>
- Orrù, G., Monaro, M., Conversano, C., Gemignani, A. & Sartori, G. (2020). Machine Learning in Psychometrics and Psychological Research. *Frontiers in Psychology*, 10. <https://doi.org/10.3389/fpsyg.2019.02970>
- Papadimitriou, C. H., Vempala, S. S., Mitropolsky, D., Collins, M. & Maass, W. (2020). Brain computation by assemblies of neurons. *Proceedings of the National Academy of Sciences*, 117(25), 14464–14472. <https://doi.org/10.1073/pnas.2001893117>
- Petermann, F. & Eid, M. (2006). *Handbuch der Psychologie: Handbuch der Psychologischen Diagnostik*. Hogrefe Verlag.
- Roy, A. (2012). A theory of the brain: localist representation is used widely in the brain. *Frontiers in Psychology*, 3. <https://doi.org/10.3389/fpsyg.2012.00551>

- Rush, A., Fava, M., Wisniewski, S. R., Lavori, P. W., Trivedi, M. H., Sackeim, H. A., Thase, M. E., Nierenberg, A. A., Quitkin, F. M., Kashner, T., Kupfer, D. J., Rosenbaum, J. F., Alpert, J., Stewart, J. W., McGrath, P. J., Biggs, M. M., Shores-Wilson, K., Lebowitz, B. D., Ritz, L., . . . STAR*D Investigators Group. (2004). Sequenced treatment alternatives to relieve depression (STAR*D): rationale and design. *Controlled Clinical Trials*, 25(1), 119–142. [https://doi.org/10.1016/s0197-2456\(03\)00112-0](https://doi.org/10.1016/s0197-2456(03)00112-0)
- Sauer, S., Buettner, R., Heidenreich, T., Lemke, J., Berg, C. & Kurz, C. (2018). Mindful Machine Learning. *European Journal of Psychological Assessment*, 34(1), 6–13. <https://doi.org/10.1027/1015-5759/a000312>
- Sauer, S., Walach, H., Offenbacher, M., Lynch, S. & Kohls, N. (2011). Measuring Mindfulness: A Rasch Analysis of the Freiburg Mindfulness Inventory. *Religions*, 2(4), 693–706. <https://doi.org/10.3390/rel2040693>
- Schmidt-Atzert, L. & Amelang, M. (2012). *Psychologische Diagnostik (Lehrbuch mit Online-Materialien)*. Springer.
- Shipp, M. A., Ross, K. N., Tamayo, P., Weng, A. P., Kutok, J. L., Aguiar, R. C., Gaasenbeek, M., Angelo, M., Reich, M., Pinkus, G. S., Ray, T. S., Koval, M. A., Last, K. W., Norton, A., Lister, T. A., Mesirov, J., Neuberg, D. S., Lander, E. S., Aster, J. C. & Golub, T. R. (2002). Diffuse large B-cell lymphoma outcome prediction by gene-expression profiling and supervised machine learning. *Nature Medicine*, 8(1), 68–74. <https://doi.org/10.1038/nm0102-68>
- Shorten, C. & Khoshgoftaar, T. M. (2019). A survey on Image Data Augmentation for Deep Learning. *Journal of Big Data*, 6(1). <https://doi.org/10.1186/s40537-019-0197-0>
- Spivak, B. L. & Shepherd, S. M. (2020). Machine learning and forensic risk assessment: new frontiers. *The Journal of Forensic Psychiatry & Psychology*, 31(4), 571–581. <https://doi.org/10.1080/14789949.2020.1779783>

- Stachl, C., Pargent, F., Hilbert, S., Harari, G. M., Schoedel, R., Vaid, S., Gosling, S. D. & Bühner, M. (2020). Personality Research and Assessment in the Era of Machine Learning. *European Journal of Personality*, 34(5), 613–631. <https://doi.org/10.1002/per.2257>
- Sutton, R. S. & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2. Aufl.). MIT Press.
- Tortora, L., Meynen, G., Bijlsma, J., Tronci, E. & Ferracuti, S. (2020). Neuroprediction and A.I. in Forensic Psychiatry and Criminal Justice: A Neurolaw Perspective. *Frontiers in Psychology*, 11. <https://doi.org/10.3389/fpsyg.2020.00220>
- Tymofiyeva, O., Yuan, J. P., Huang, C. Y., Connolly, C. G., Henje Blom, E., Xu, D. & Yang, T. T. (2019). Application of machine learning to structural connectome to predict symptom reduction in depressed adolescents with cognitive behavioral therapy (CBT). *NeuroImage: Clinical*, 23, 101914. <https://doi.org/10.1016/j.nicl.2019.101914>
- Ullal, M. S., Hawaldar, I. T., Soni, R. & Nadeem, M. (2021). The Role of Machine Learning in Digital Marketing. *SAGE Open*, 11(4), 215824402110503. <https://doi.org/10.1177/21582440211050394>
- Wang, T., Wang, Y., Shen, J., Wang, L. & Cao, L. (2022). Predicting Spike Features of Hodgkin-Huxley-Type Neurons With Simple Artificial Neural Network. *Frontiers in Computational Neuroscience*, 15. <https://doi.org/10.3389/fncom.2021.800875>
- Wiecki, T. V., Antoniades, C. A., Stevenson, A., Kennard, C., Borowsky, B., Owen, G., Leavitt, B., Roos, R., Durr, A., Tabrizi, S. J. & Frank, M. J. (2016). A Computational Cognitive Biomarker for Early-Stage Huntington's Disease. *PLOS ONE*, 11(2), e0148409. <https://doi.org/10.1371/journal.pone.0148409>
- Wiecki, T. V., Poland, J. & Frank, M. J. (2015). Model-Based Cognitive Neuroscience Approaches to Computational Psychiatry. *Clinical Psychological Science*, 3(3), 378–399. <https://doi.org/10.1177/2167702614565359>

- Wolfers, T., Buitelaar, J. K., Beckmann, C. F., Franke, B. & Marquand, A. F. (2015). From estimating activation locality to predicting disorder: A review of pattern recognition for neuroimaging-based psychiatric diagnostics. *Neuroscience & Biobehavioral Reviews*, 57, 328–349. <https://doi.org/10.1016/j.neubiorev.2015.08.001>
- Xu, C. & Jackson, S. A. (2019). Machine learning and complex biological data. *Genome Biology*, 20(1). <https://doi.org/10.1186/s13059-019-1689-0>
- Yan, W., Calhoun, V., Song, M., Cui, Y., Yan, H., Liu, S., Fan, L., Zuo, N., Yang, Z., Xu, K., Yan, J., Lv, L., Chen, J., Chen, Y., Guo, H., Li, P., Lu, L., Wan, P., Wang, H., . . . Sui, J. (2019). Discriminating schizophrenia using recurrent neural network applied on time courses of multi-site fMRI data. *EBioMedicine*, 47, 543–552. <https://doi.org/10.1016/j.ebiom.2019.08.023>
- Yang, B., Chen, Y., Shao, Q. M., Yu, R., Li, W. B., Guo, G. Q., Jiang, J. Q. & Pan, L. (2019). Schizophrenia Classification Using fMRI Data Based on a Multiple Feature Image Capsule Network Ensemble. *IEEE Access*, 7, 109956–109968. <https://doi.org/10.1109/access.2019.2933550>
- Zeng, L. L., Wang, H., Hu, P., Yang, B., Pu, W., Shen, H., Chen, X., Liu, Z., Yin, H., Tan, Q., Wang, K. & Hu, D. (2018). Multi-Site Diagnostic Classification of Schizophrenia Using Discriminant Deep Learning with Functional Connectivity MRI. *EBioMedicine*, 30, 74–85. <https://doi.org/10.1016/j.ebiom.2018.03.017>
- Zhao, J., Huang, J., Zhi, D., Yan, W., Ma, X., Yang, X., Li, X., Ke, Q., Jiang, T., Calhoun, V. D. & Sui, J. (2020). Functional network connectivity (FNC)-based generative adversarial network (GAN) and its applications in classification of mental disorders. *Journal of Neuroscience Methods*, 341, 108756. <https://doi.org/10.1016/j.jneumeth.2020.108756>

Eidesstattliche Erklärung

Hiermit versichere ich, dass ich die vorliegende Arbeit ohne Hilfe Dritter und ohne Benutzung anderer als der angegebenen Quellen und Hilfsmittel angefertigt, die den benutzten Quellen wörtlich oder inhaltlich entnommenen Stellen als solche kenntlich gemacht und die Satzung der Universität Ulm zur Sicherung guter wissenschaftlicher Praxis in der aktuell gültigen Fassung beachtet habe.

Illerkirchberg, den 6. Mai 2022

Ort, Datum



Unterschrift